Практическая применимость проекта

Мультиагентная система на основе LLM для генерации и проверки математических задач · тема № 99
Борщев Аристарх Александрович · куратор Голубев Александр
Разведочный анализ данных: ноутбук в Google Colab

> **Кратко.** Telegram-бот по запросу «класс, формат, тема» выдаёт новую задачу в стиле МЦКО, ВПР или ОГЭ с проверенным решением и находит ошибки в решении ученика. Модели не обучаются: работа идёт через API LLM, ответы проверяются в SymPy.

1. Чью боль решает

Кто	Проблема	Что даёт система
Учителя	Долго подбирать задачи и варианты; открытые банки быстро заучиваются	Новые задачи нужного класса и формата за минуту
Школьники	Мало демоверсий, никто не разбирает ошибки	Неограниченная практика и указание шага с ошибкой
Репетиторы и онлайн-школы	Варианты составляются и проверяются вручную	Готовые варианты с решениями

2. Насколько реалистично

Технически решение реализуемо уже сейчас: обучать модели не нужно, бот не требует установки, а одна задача стоит несколько запросов к модели — дешевле минуты работы преподавателя. Основные трудности:

Риск	Уровень	Как снижаем
Ошибка в условии или решении	● высокий	Независимая перепроверка, проверка ответа в SymPy, отказ выдавать задачу при несогласии агентов, кнопка «сообщить об ошибке»
Нет данных в нужном формате	● высокий	Открытые наборы англоязычные; банк МЦКО, ОГЭ и ВПР собирается вручную из демоверсий и банка ФИПИ
Форматы экзаменов меняются	● средний	Генерация по образцам: достаточно обновить примеры, без переобучения
Геометрия и рисунки	● средний	Около 2/3 задач с рисунком; на первом этапе раздел ограничен
Стоимость и доступ к API	● средний	Поддержка нескольких моделей, включая открытые; кеш готовых задач
Списывание, данные учеников	● низкий	Решение показывается после попытки; персональные данные не собираются

3. Как заказчику оценивать качество

Метрика	Как измеряем
Корректность	Доля задач без ошибок в выборке, проверенной учителем
Похожесть на экзамен	Слепой тест: учителя отличают настоящие задачи от сгенерированных; цель — около 50 % угадываний
Соответствие классу и теме	Оценка учителей; доля задач, отклонённых методистом
Польза для пользователя	Время на подготовку варианта, повторное использование бота, доля жалоб, цена одной задачи

4. Ценность помимо продукта

Исследовательский результат: насколько мультиагентная проверка и SymPy снижают ошибки LLM по сравнению с одной моделью и в каких темах генерация пока ненадёжна. Отдельно изучается **формальная проверка в Lean 4**: как точно LLM переводит школьные задачи на язык Lean и какие ошибки ловит такая проверка.